

Dataset

Tesina di Metodologie Statistiche per i Big Data

Marco Belardinelli

Obiettivi della presentazione



- Provare quale tra i vari metodi a nostra disposizione è il migliore per fare previsioni sul nostro dataset
- Analisi delle variabili che più influiscono sulla classificazione
- Differenze tra metodi supervisionati e non supervisionati

Pulizia dataset

```
> dim(mobile_train_df)
[1] 2000 21
```

Nel dataset troviamo 21 variabili e 2000 osservazioni.

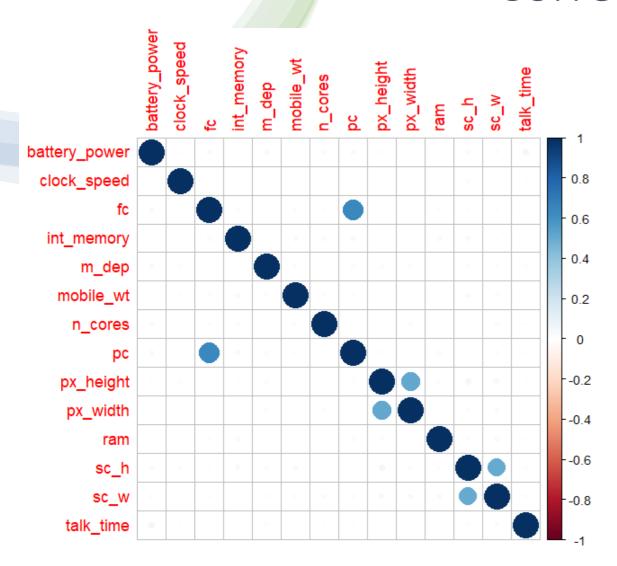
```
battery_power blue clock_speed dual_sim fc four_g int_memory m_dep mobile_wt n_cores pc px_height
                          2.2
                                                               0.6
        1021
                                                                         136
                          0.5
                                                          53
         563
                          0.5
                                                              0.9
                                                                         145
                                                                                              1263
                                                                                             1216
                                                                         131
         615
                          2.5
                                                              0.8
        1821
                                                              0.6
                                                                         141
                                                                                              1208
                                                          22
                                                              0.7
        1859
                                                                                              1004
px_width    ram sc_h sc_w talk_time three_g touch_screen wifi price_range
                              9
11
15
               11
```

Alcune variabili sono numeriche altre binomiali.

```
mobile_train_df$blue = as.factor(mobile_train_df$blue)
mobile_train_df$dual_sim = as.factor(mobile_train_df$dual_sim)
mobile_train_df$four_g = as.factor(mobile_train_df$four_g)
mobile_train_df$three_g = as.factor(mobile_train_df$three_g)
mobile_train_df$touch_screen = as.factor(mobile_train_df$touch_screen)
mobile_train_df$wifi = as.factor(mobile_train_df$wifi)
mobile_train_df$price_range = as.factor(mobile_train_df$price_range)
```

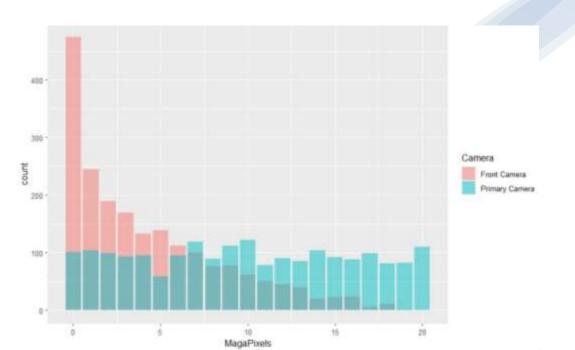
Non sono presenti osservazioni doppie o con valori mancanti procediamo quindi a trasformare le variabili binomiali in fattori.

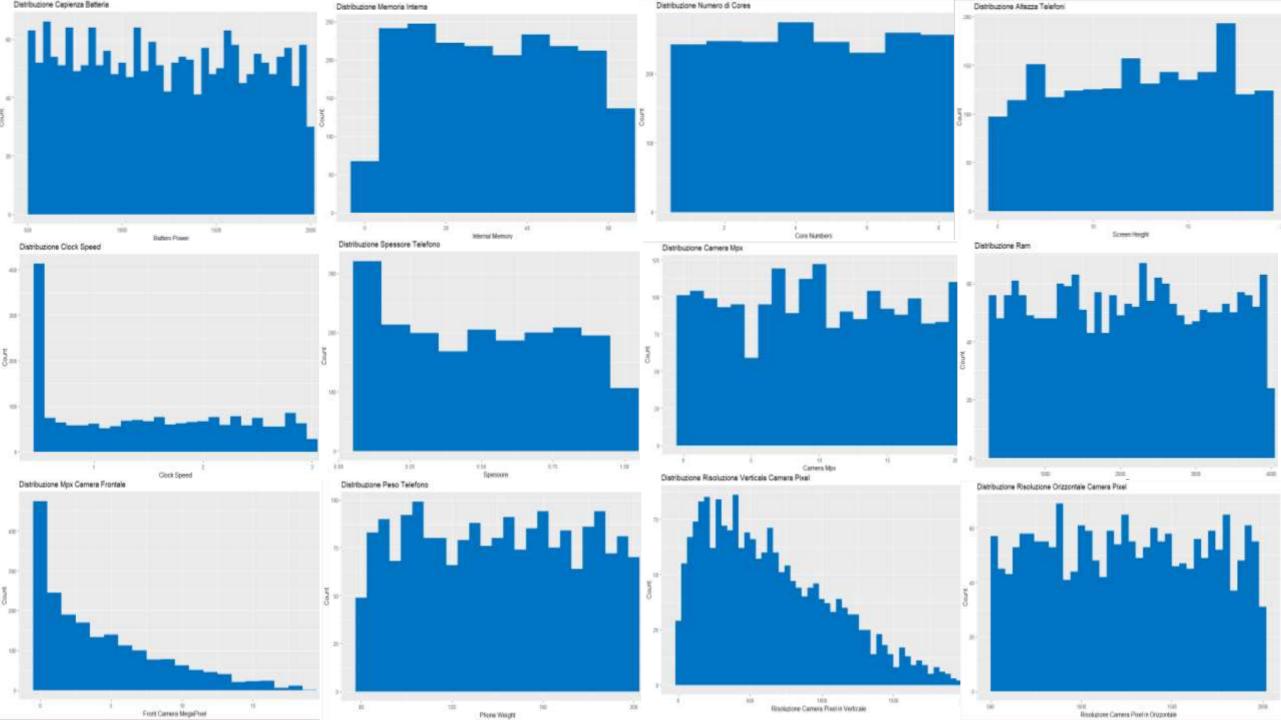
Correlazioni



Con questa tabella cerchiamo eventuali correlazioni tra le variabili, notiamo:

- risoluzione pixel in altezza risoluzione pixel in larghezza (0.51)
- altezza schermo larghezza schermo (0.51)
- fotocamera interna fotocamera principale (0.64)





Standardizzazione Variabili e Divisione Train-Test

Al fine di procedere con le previsioni standardizziamo le nostre variabili

```
> numeric_data = mobile_train_df[,c(1,3,5,7:17)]
> fun_norm = function(x){
+         return((x-mean(x))/sd(x))
+ }
> data_std = as.data.frame(lapply(numeric_data, fun_norm))
> data = data.frame(data_std, mobile_train_df[,c(2,4,6,18:21)])
```

```
... per poi dividerle in TRAIN & TEST.
```

Confrontando i due subset vediamo che la variabile che andremo a studiare si distribuisce equamente in entrambi.

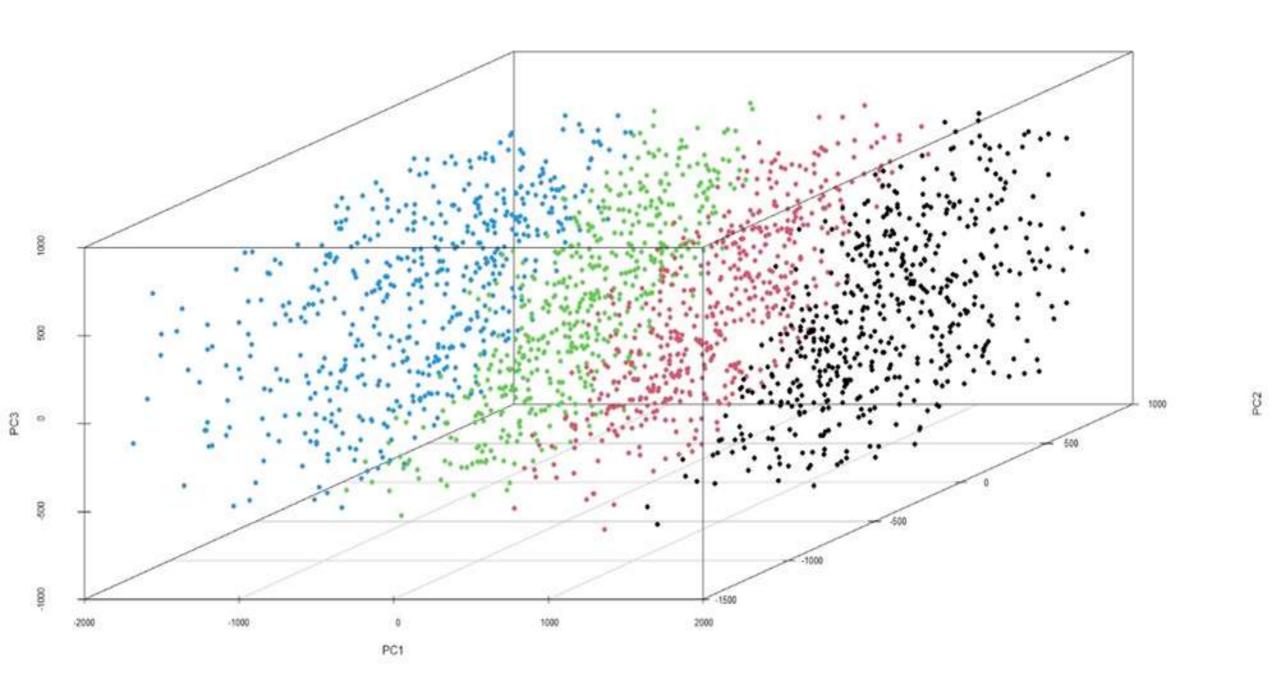
Principal Component Analysis (PCA)

```
Importance of components:
                             PC1
                                      PC2
                                               PC3
                                                         PC4
                                                                   PC5
                                                                            PC6
                                                                                    PC7
                                                                                            PC8
Standard deviation
                       1084,7779 538,4416 439,5203 305,99036 35,40763 18,12040 6,84271
Proportion of Variance
                          0.6704
                                   0.1652
                                             0.1101
                                                               0.00071
                                                                        0.00019 0.00003 0.00002
                                   0.8356
Cumulative Proportion
                          0.6704
                                             0.9457
                                                      0.99903
                                                              0.99974
                                                                        0.99993 0.99995 0.99997
                                                      PC13
                                       PC11 PC12
                                                            PC14
Standard deviation
                       5.22756 3.02570 2.914 2.281 0.815
                                                            . 2877
Proportion of Variance 0.00002 0.00001 0.000 0.000 0.0000
                                                           0.0000
Cumulative Proportion 0.99999 0.99999 1.000 1.000 1.000
                                                           1.0000
```

Sommando le prime quattro componenti principali arriviamo al 99% varianza totale.

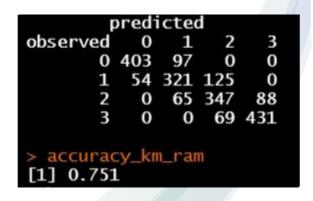
Avevamo già visto quali variabili erano le più significative, gli autovettori delle prime quattro PC ci confermano la loro utilità.

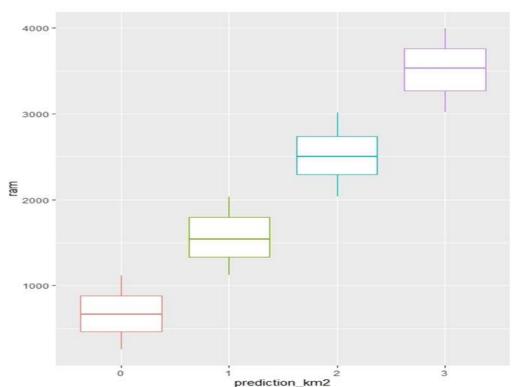
```
pcav$rotation
                        PC1
                                      PC2
                                                     PC3
                                                                   PC4
               3.471979e-04 -1.038840e-02
battery_power
                                           9.994425e-01 -3.171326e-02
clock_speed
                            2.087359e-05
              -2.630029e-06
                                           2.144006e-05 -1.396166e-05
fc
              -6.055997e-05
                             6.733209e-05
                                           3.293617e-04 -8.234845e-05
int_memory
              -5.482375e-04 -6.847613e-05 -1.472883e-04
                                                          1.190878e-03
m_dep
               2.534142e-06 -1.515199e-05
                                           2.212233e-05 -6.542344e-07
mobile_wt
               8.443485e-05 -3.911582e-05
                                           1.500664e-04
                                                          8.096725e-05
              -1.035355e-05 -3.924499e-05 -1.588837e-04 -2.275485e-04
n_cores
                             9.088395e-05
              -1.624202e-04
                                           4.286954e-04
                                                         -4.638556e-04
pc
px_height
               9.903074e-03 -7.250362e-01 1.430758e-02
                                                          6.884899e-01
px_width
              -9.647755e-04 -6.886014e-01 -3.014695e-02
                                                         -7.245119e-01
              -9.999503e-01 -6.519582e-03 5.178224e-04
                                                          7.505923e-03
ram
sc_h
              -6.123714e-05 -3.718628e-04 -2.846868e-04
                                                          5.401018e-04
SC_W
              -1.422252e-04 -3.656035e-04 -2.157749e-04
                                                          1.337468e-04
talk_time
              -5.468870e-05 2.090449e-05 6.481607e-04 -3.502860e-04
```



K-Means

```
km2 = kmeans(scale(numeric_data[,11]), centers = 4, nstart = 100)
prediction_km2 = as.factor(km2$cluster -1)
cluster_km2 = data.frame(mobile_train_df, prediction_km2)
conf_km_ram = table(cluster_km2$price_range,cluster_km2$prediction_km2)
names(dimnames(conf_km_ram)) = c( "observed", "predicted")
cluster_km2$prediction_km2[cluster_km2$prediction_km2 == "2"] = "5"
cluster_km2$prediction_km2[cluster_km2$prediction_km2 == "3"] = "2"
cluster_km2$prediction_km2[is.na(cluster_km2$prediction_km2)] = "3"
accuracy_km_ram = sum(diag(conf_km_ram))/2000
```





prediction km2

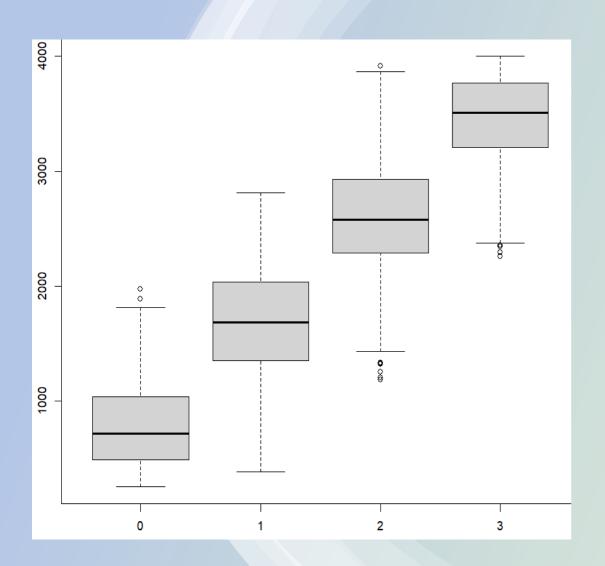
1 2

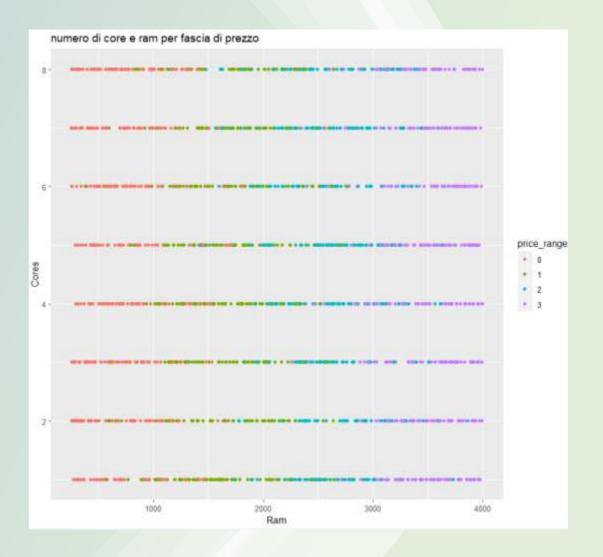
Nearest Neighbor

Con K=20 ovvero la radice del numero di osservazioni del nostro dataset abbiamo ottenuto un'accuracy elevata.

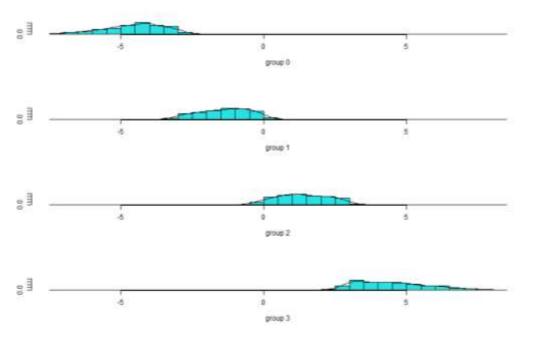
Tuttavia, con un K più alto l'accuracy sale poiché le nostre classi sono equamente popolate quindi non abbiamo il rischio che un osservazione finisca nella classe più numerosa.

RAM & PRICE RANGE



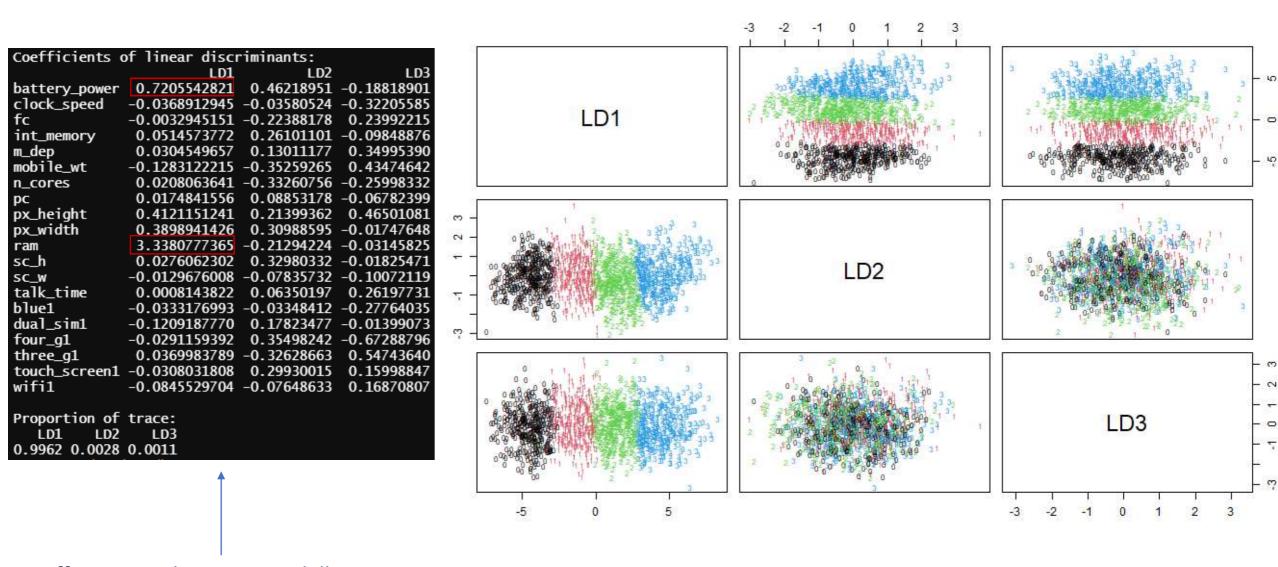


Analisi Discriminante



Andando a vedere la Confusion Matrix infatti:

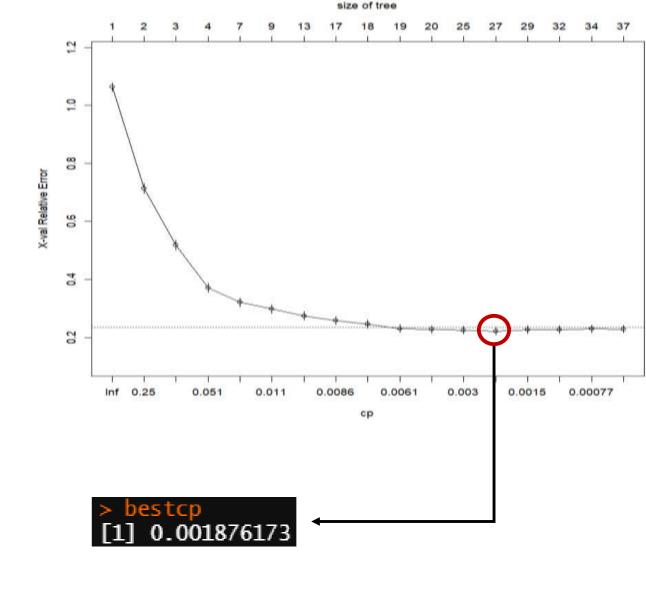
L'immagine parla da sola, l'analisi discriminante sembra essere un ottimo metodo per fare previsioni su questo dataset



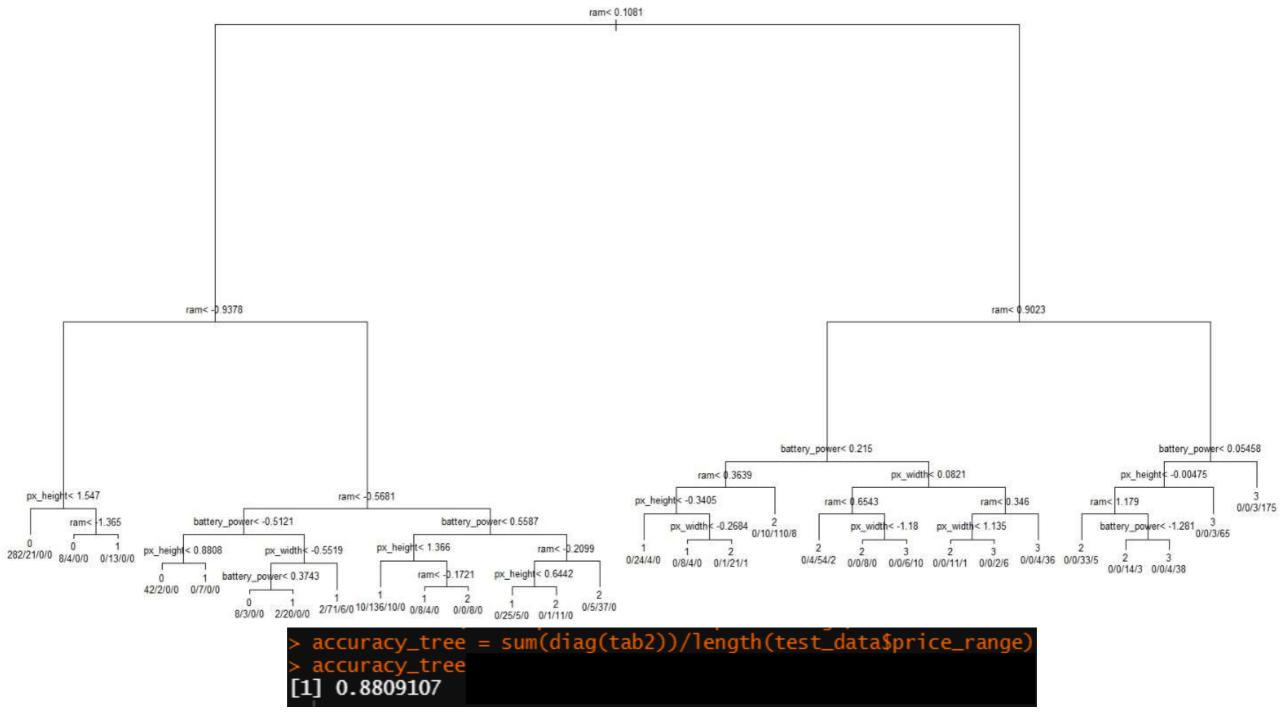
Coefficienti per la creazione delle funzioni discriminanti.

Decision Tree

```
tree<-rpart(price_range~., data = train_data,
control = rpart.control(cp=0.0001),
parms = list(split="gini"))
```

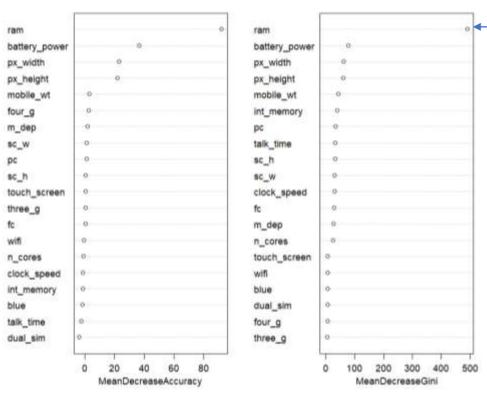


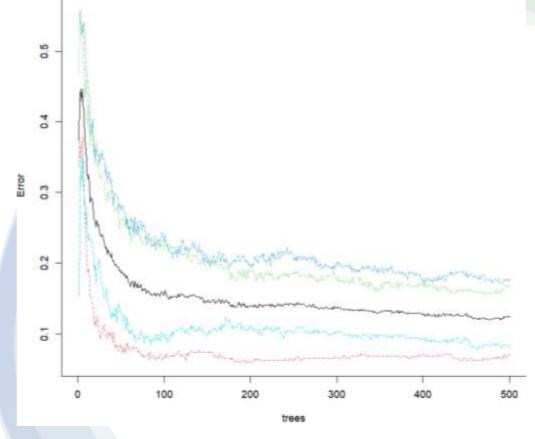
Variables actually used in tree construction:
[1] battery_power px_height px_width ram

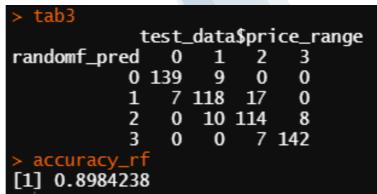


Random Forest

Come possiamo vedere dal grafico che plotta l'importanza delle variabili utilizzate nella random forest, la ram surclassa tutte le altre rendendole pressochè inutili.







Accuracy elevata anche con questo algoritmo.

Conclusioni

- L'algoritmo che meglio classifica le nostre osservazioni è l'analisi discriminante 95,45%.
- Le variabili che più influiscono sul price range sono: ram, capienza batteria, larghezza e altezza schermo (elevata accuratezza anche considerando solamente la ram).
- Nonostante non fossero presenti le quattro classi anche con i metodi non supervisionati siamo riusciti ad ottenere un accuracy del 75%.

GRAZIE PER L'ATTENZIONE